

Predicción de resultados del fútbol uruguayo

1st Agustin Bolazzi Peña
Facultad de ingeniería
Udelar
agubope@gmail.com

2nd Agustin Machado Carusini
Facultad de ingeniería
Udelar
machadoagus02@gmail.com

3rd Matias Sención Garcia
Facultad de ingeniería
Udelar
matiasseccion@gmail.com

Abstract—En este documento se presenta el informe de predicción de partidos de fútbol en base a Árboles de Decisión y modelos de Naive Bayes. Partiendo de un conjunto de datos específico de todos los partidos del fútbol uruguayo desde 1932 hasta 2025, se preprocesan los datos y se entrenan los modelos para lograr predecir los resultados de los partidos.

Index Terms—Aprendizaje Automático, Árboles de Decisión, Naives Bayes, Fútbol Uruguayo

I. OBJETIVO

El objetivo de esta tarea es construir un Árbol de Decisión y un Clasificador Naive Bayes para predecir el resultado de partidos de fútbol. Ambos modelos aprenderán de un conjunto de datos que será preprocesado que tiene el registro de todos los partidos del fútbol uruguayo desde 1932 a 2025. El rendimiento de estos clasificadores será medido con las métricas acordes para esta tarea, y comparado tanto con un clasificador base como con las implementaciones de referencia de scikit-learn de Random Forest y Naive Bayes categórico, de modo de contrastar las implementaciones propias frente a alternativas de biblioteca sobre el mismo conjunto de atributos.

II. DISEÑO

A. Preprocesamiento de datos

Se utilizó un conjunto de datos de partidos del fútbol uruguayo correspondientes al período 1932–2025, proporcionado por los docentes y procedente del repositorio *football-data* [5].

El conjunto original incluye los equipos local y visitante, la fecha, los goles de ambos equipos, el tipo de finalización del encuentro (tiempo reglamentario, alargue o penales), la competición, los identificadores de los equipos, sus países, códigos de país y continentes, además del continente y el ámbito nacional o internacional de la competición.

Para la construcción del clasificador, se seleccionaron los siguientes atributos:

- Equipo local (*home*).
- Equipo visitante (*away*).
- Fecha del encuentro (*date*).
- Goles del equipo local (*gh*).
- Goles del equipo visitante (*ga*).

Antes de continuar, se verificó la ausencia de datos faltantes en las columnas utilizadas y se eliminaron los registros duplicados exactos mediante `drop_duplicates()`.

Posteriormente, se identificaron encuentros entre los mismos equipos registrados en una misma fecha con distintos marcadores. Mediante la consulta de las bases históricas 1891 y RSSSF, y del archivo periodístico de LARED21, se comprobó que cuatro grupos correspondían a partidos diferentes: los desempates Rampla–Miramar de 1987 [1], las finales Peñarol–Defensor de 1994 y 1997 [2], [3], y los encuentros Danubio–Nacional del Apertura y la Liguilla de 1996 [4].

Se conservaron los encuentros y se corrigieron diez fechas. Para Rampla–Miramar, al no disponer de las fechas exactas, se asignaron provisionalmente días consecutivos. Para los dos empates de las finales de 1994, se utilizaron las fechas documentadas siguiendo el orden de aparición de los registros.

También se detectaron casos de equipos enfrentando a distintos rivales en una misma fecha. Estos permanecen pendientes de resolución, dado que no se dispone de información suficiente para corregirlos todos. Las diferencias de un día observadas en algunos encuentros recientes se conservaron, al no poder confirmar el criterio horario de la fuente.

Finalmente, se verificó que los ocho encuentros identificados como definidos por penales ya excluían los goles de la tanda. Se conservaron estos marcadores y los correspondientes a partidos con alargue; por tanto, el resultado considerado incluye la prórroga cuando corresponde.

A continuación, se definió el atributo calculado *Result*, con los siguientes valores:

- L: si el equipo local marcó más goles que el visitante.
- V: si el equipo visitante marcó más goles que el local.
- E: si ambos equipos marcaron la misma cantidad de goles.

Para representar el desempeño previo de los equipos se definen atributos calculados que sean capaces de representar quién podría ser el ganador de un partido. A continuación se listan los definidos:

- **Record Difference:** Se calcula en base al porcentaje de victorias de cada equipo contemplando el último año de historial. Si el valor es positivo significa que el equipo local tuvo mejor desempeño general y si es negativo significa que el visitante tuvo mejor desempeño.
- **Last Matches Difference:** Se calcula en base a la tasa de puntos obtenidos en los últimos 5 partidos jugados por cada equipo, usando el sistema típico (3 puntos por victoria, 1 por empate, 0 por derrota). Si el valor es positivo el equipo local viene con una mejor racha y si es negativo el visitante viene mejor.

- **Goal Difference Value:** Se calcula contrastando la diferencia de goles promedio del equipo local (contemplando exclusivamente sus partidos jugando en casa) contra la diferencia de goles promedio del visitante (contemplando exclusivamente sus partidos jugando fuera). Si el valor es positivo el equipo local presenta mejor saldo de goles en su respectiva condición.
- **Attack Difference:** Se calcula restando el promedio de goles a favor del equipo local (jugando en casa) menos el promedio de goles a favor del visitante (jugando fuera). Si el valor es positivo indica que el equipo local tiene mayor poder ofensivo en casa que el visitante fuera.
- **Defense Difference:** Se calcula restando el promedio de goles recibidos por el visitante (jugando fuera) menos los goles recibidos por el local (jugando en casa). Al estar invertido, recibir menos goles aumenta el valor, por lo que si es positivo indica que el equipo local tiene mejor solidez defensiva.
- **Head-to-Head (H2H) Difference:** Se calcula en base a la tasa de puntos obtenidos en los enfrentamientos directos entre ambos equipos a lo largo de los últimos 5 años. Si el valor es positivo el equipo local tiene ventaja histórica reciente sobre el visitante.
- **Rest Days Difference:** Se calcula restando los días transcurridos desde el último partido del visitante a los del local. Si el valor es positivo significa que el equipo local llega con más días de descanso, y si es negativo el visitante llega más descansado.
- **ELO Difference:** Se calcula como la diferencia entre el puntaje ELO acumulado del equipo local y el visitante justo antes de comenzar el encuentro. Si el valor es positivo, el historial ponderado de ELO considera al equipo local superior, y si es negativo favorece al visitante.
- **Draw Rate Average:** Se calcula promediando el porcentaje histórico de empates que tienen el equipo local y el visitante en el último año. Este atributo no mide ventajas; un valor alto indica una fuerte tendencia conjunta de ambos equipos a terminar sus partidos en empate.
- **ELO Closeness:** Se calcula obteniendo el valor absoluto de la diferencia de ELO entre ambos equipos. Sirve para medir qué tan parejo es el encuentro sin importar quién es superior; un valor más bajo indica que las fuerzas de ambos equipos son muy similares.
- **Local Experience:** Se calcula evaluando la cantidad de partidos previos que el equipo local tiene registrados en el historial, asignándole un nivel discreto de 0 (sin información) a 3 (información suficiente) que refleja la confiabilidad de sus estadísticas.
- **Away Experience:** Se calcula bajo la misma lógica discreta (de 0 a 3) pero para evaluar la madurez de la información histórica disponible del equipo visitante.
- **Record Enough:** Se calcula de forma booleana (1 o 0) verificando si ambos equipos ya han jugado al menos la cantidad mínima requerida de partidos en el historial (5 partidos). Si vale 1, las métricas previas de ambos se consideran representativas.

Los atributos numéricos comparativos se discretizaron antes de su ingreso al clasificador. Para cada diferencia entre equipos, se utilizó un margen que determina tres categorías: ventaja local, paridad y ventaja visitante. Los valores superiores al margen indican ventaja local, los inferiores a su opuesto indican ventaja visitante y los restantes representan paridad. La tasa promedio de empates se dividió en niveles bajo, medio y alto mediante dos umbrales. De forma análoga, la paridad del encuentro (*elo_closeness*, el valor absoluto de la diferencia de ELO) se discretizó en niveles bajo, medio y alto mediante dos umbrales adicionales, produciendo el atributo *match_evenness*.

La discretización y la codificación de las categorías se integraron con el clasificador en un *pipeline*, de modo que la misma transformación se aplica durante el entrenamiento y la predicción. Los márgenes y umbrales se trataron como hiperparámetros, cuya selección se describe en la sección de evaluación II-C.

B. Algoritmos

1) *Clasificador Base:* Se utilizó un clasificador base como referencia de desempeño para evaluar si los modelos desarrollados ofrecen mejoras respecto a una estrategia sencilla.

La predicción se obtiene comparando la proporción de victorias de ambos equipos durante los últimos diez años. Se predice una victoria del equipo con mayor proporción de triunfos y, cuando ambas proporciones coinciden, se predice un empate.

2) *Árboles de Decisión:* Los árboles de decisión son modelos de aprendizaje supervisado que permiten predecir una clase a partir de un conjunto de atributos. Su estructura es jerárquica: los nodos internos contienen condiciones sobre los atributos, las ramas representan los posibles resultados de dichas condiciones y las hojas indican la clase predicha.

Durante la construcción del árbol, se seleccionan sucesivamente primero aquellos atributos que permiten reducir la incertidumbre sobre la clase objetivo. En esta implementación, el criterio de selección de atributos utilizado es la Ganancia de información basada en la entropía, en su formulación estándar para el algoritmo ID3, presentada en el material teórico del curso [7].

Debido a que el algoritmo ID3 trabaja de forma nativa con atributos categóricos, no incluye un mecanismo para el manejo de valores continuos, es por eso que fue fundamental la etapa previa de discretización de los datos. Además, dado que el ID3 clásico no incluye un criterio de parada más allá de la pureza de las hojas, se incorporaron dos hiperparámetros de regularización ausentes en la formulación original: un soporte mínimo de instancias por hoja (*min_samples_leaf*) y una ganancia de información mínima requerida para realizar una división (*min_info_gain*). Ambos se seleccionaron junto con los márgenes de discretización mediante el mismo protocolo de validación cruzada temporal descrito en la Sección II-C.

3) *Naive Bayes:* Naive Bayes es un clasificador probabilístico basado en el teorema de Bayes, que supone independencia condicional entre los atributos dada la clase. Para

cada instancia, se estima la probabilidad posterior de las clases posibles y se selecciona aquella con mayor probabilidad.

En esta implementación, se utilizó m-estimación para suavizar las probabilidades estimadas [8]. Esta técnica combina las frecuencias observadas con probabilidades a priori y permite evitar probabilidades nulas para valores no observados en una clase durante el entrenamiento, siempre que se les asigne una probabilidad a priori positiva.

Además, para mitigar la inestabilidad numérica producida por las productorias de números cercanos a cero, se aplica la función logaritmo [8]:

$$v_{NB} = \arg \max_{v_i \in V} \left[\log(P(v_i)) + \sum_j \log(P(a_j|v_i)) \right] \quad (1)$$

Otro punto que vale la pena destacar de esta implementación de Naive Bayes es la inclusión del hiperparámetro *"fit_prior"*. El mismo hace alternar a la función de cálculo de probabilidades del modelo, de modo que si se encuentra en *true*, se calcula la probabilidad real de cada clase en el conjunto de entrenamiento, de la forma:

$$P(v_i) = \frac{N_{v_i}}{N} \quad (2)$$

donde N_{v_i} representa el número de instancias de la clase v_i , y N representa el número total de instancias. Por otra parte, si el valor de *"fit_prior"* es *false*, entonces se considera que todas las clases son equiprobables a priori, asignándoles a todas el siguiente valor:

$$P(v_i) = \frac{1}{|V|} \quad (3)$$

siendo V el conjunto de todas las clases posibles. La motivación detrás de la implementación de este hiperparámetro surge del gran desbalance en el número de instancias correspondientes a cada clase que existe en el conjunto de datos. Frente a este hecho, se decidió realizar el ajuste mencionado sobre Naive Bayes, para posteriormente, en la etapa de evaluación, determinar mediante validación cruzada, cuál de las dos alternativas obtenía mejores resultados.

Si bien los detalles de la evaluación se explican de mejor forma en la siguiente sección II-C, cabe destacar que los mejores resultados se obtuvieron al establecer *"fit_prior"* en *false*, y por lo tanto, utilizando la versión equiprobable de la implementación.

4) *Random Forest (scikit-learn)*: A diferencia del ID3 individual, Random Forest combina las predicciones de múltiples árboles entrenados sobre subconjuntos aleatorios de atributos e instancias (*bootstrap*). Al recibir los mismos atributos discretizados y codificados ordinalmente que el resto de los modelos, no requirió tratamiento adicional de atributos faltantes o numéricos. La extensión relevante frente al ID3 propio consistió en seleccionar mediante el mismo protocolo de validación cruzada temporal los hiperparámetros que gobiernan el ensamble (*n_estimators*, profundidad máxima, criterio de división, cantidad de atributos considerados por

división) y, en particular, la estrategia de ponderación de clases (*class_weight*), relevante dado el desbalance entre empates y victorias/derrotas.

5) *Naive Bayes categórico (scikit-learn)*: Se utilizó *CategoricalNB* como contraste de biblioteca frente a la implementación propia con m-estimación. Al recibir atributos ya discretizados y codificados como enteros ordinales, fue necesario especificar explícitamente la cardinalidad de cada atributo (*min_categories*) para que el modelo reserve probabilidad a categorías no observadas durante el entrenamiento de cada fold temporal — un tratamiento equivalente en propósito al suavizado del m-estimador de la implementación propia, aunque resuelto de forma distinta.

C. Evaluación

Se separaron los datos cronológicamente, de modo que los partidos anteriores al 1 de enero de 2024 conformaron el conjunto de entrenamiento utilizado para ajuste de hiperparámetros, mientras que los encuentros de 2024 y 2025 se reservaron como conjunto de test, sin intervenir en la selección de configuraciones.

Para los cuatro clasificadores (ID3, Naive Bayes, Random Forest y Naive Bayes categórico) se utilizó validación cruzada temporal con una ventana móvil de cinco años. Se construyeron diecinueve particiones, una por cada año de validación entre 2005 y 2023. Para validar un año a , se entrenó exclusivamente con los partidos de los años $a-5$ a $a-1$; por ejemplo, la primera partición utilizó 2000–2004 para entrenar y 2005 para validar, y la última utilizó 2018–2022 y 2023 (últ. año completo antes del test), para validar. Se priorizó este período reciente para orientar la selección de configuraciones hacia el contexto del fútbol actual, y se mantuvo el mismo tamaño de ventana que el utilizado en el ajuste final (descrito más abajo), para que los hiperparámetros seleccionados sean representativos de las condiciones de entrenamiento del modelo evaluado.

Los hiperparámetros de cada clasificador, junto con los márgenes de discretización compartidos, se seleccionaron mediante *RandomizedSearchCV*, evaluando 500 configuraciones por modelo con semilla fija (42) para reproducibilidad, y eligiendo en cada caso la configuración de mayor F1 macro medio entre los diecinueve años.

En cada partición se entrenó un modelo independiente, manteniéndolo fijo durante el año validado. Los atributos históricos de cada encuentro se calcularon utilizando únicamente partidos de fechas anteriores. Por tanto, los resultados ya conocidos dentro del año de validación pueden incorporarse como antecedentes de encuentros posteriores, sin reentrenar el clasificador.

Se calcularon las siguientes métricas para las clases victoria local, empate y victoria visitante:

- *Accuracy*: proporción de predicciones correctas sobre el total de encuentros.
- *Balanced accuracy*: promedio no ponderado del *recall* de las tres clases.

- F1 macro: promedio no ponderado del F1 calculado individualmente para cada clase.

Para cada clase, la precisión representa la proporción de aciertos entre las predicciones asignadas a ella, mientras que el *recall* representa la proporción de sus casos reales identificados correctamente. El F1 combina ambas mediante su media armónica:

$$F1_c = \frac{2P_c R_c}{P_c + R_c}, \quad F1_{\text{macro}} = \frac{1}{3} \sum_{c \in \{L, E, V\}} F1_c,$$

donde P_c y R_c corresponden a la precisión y al *recall* de la clase c .

Se priorizó F1 macro porque asigna la misma importancia a cada clase, independientemente de su frecuencia, y considera tanto la precisión como el *recall*. En cambio, la *accuracy* resume los aciertos globales y puede favorecer configuraciones que predigan bien las clases frecuentes, pero identifiquen pocos empates. F1 macro permite penalizar ese comportamiento sin favorecer indiscriminadamente la predicción de empates, ya que también penaliza los falsos positivos de esa clase.

Posteriormente, se analizaron matrices de confusión y reportes por clase construidos a partir de las predicciones agrupadas de validación. Estas medidas se distinguieron de los promedios anuales empleados para seleccionar configuraciones. Los resultados de validación se utilizaron para ajustar y comparar alternativas; la estimación final del desempeño queda reservada al conjunto de test.

Por último, una vez seleccionados los hiperparámetros, se ajustó un único modelo por clasificador utilizando los partidos de 2019 a 2023 —la misma ventana de cinco años usada en los folds de validación— y se evaluó una única vez sobre el conjunto de test (2024–2025), sin reentrenamiento ni ajuste posterior de hiperparámetros a partir de esos resultados.

III. EXPERIMENTACIÓN

A continuación se presentan los resultados experimentales obtenidos durante la etapa de evaluación final, para cada uno de los modelos desarrollados: el clasificador base, ID3 y Naive Bayes de implementación propia, y Random Forest y Naive Bayes categórico de scikit-learn. Los cinco modelos se evaluaron una única vez sobre el conjunto de test (partidos de 2024 y 2025), tras haber seleccionado sus hiperparámetros exclusivamente mediante los folds de validación descritos en la Sección II-C.

En la Tabla I se compilan las tres métricas principales para los cinco modelos sobre el conjunto de test, junto con el F1 y el *recall* de la clase Empate, que es la que concentra las mayores diferencias entre modelos. El clasificador Bayes M-estimador obtiene el mejor resultado en las tres métricas generales, superando tanto a las implementaciones de scikit-learn como al árbol ID3 propio y al clasificador base.

La Figura 1 presenta gráficamente estos mismos resultados. Se observa que el clasificador base, pese a lograr una *accuracy* competitiva con los modelos entrenados (0.464), es el peor en F1 macro (0.358): al nunca predecir empates, es penalizado en

TABLE I
COMPARACIÓN DE CLASIFICADORES — CONJUNTO DE TEST (2024–2025)

Modelo	F1 macro	Acc.	Bal. Acc.	F1 Emp.	Rec. Emp.
Base (referencia)	0.358	0.464	0.428	0.00	0.00
Árbol ID3 (propio)	0.397	0.409	0.397	0.32	0.34
Bayes M-est. (propio)	0.449	0.494	0.467	0.25	0.18
Random Forest (sklearn)	0.429	0.487	0.455	0.182	0.122
NB categ. (sklearn)	0.422	0.470	0.444	0.19	0.14

la métrica que pondera igual a las tres clases, lo que confirma que la *accuracy* por sí sola no es una métrica adecuada para este problema.




Fig. 1. Comparación de clasificadores sobre el conjunto de test.

La Figura 2 muestra las matrices de confusión normalizadas por clase real. Los cinco modelos comparten una misma debilidad: el *recall* de la clase Empate nunca supera 0.34 (Árbol ID3), y el clasificador base directamente no predice ningún empate (*recall* 0.00). La mayor parte de los empates mal clasificados se confunde con victoria local, lo que sugiere que los atributos utilizados, orientados principalmente a distinguir ventaja de un equipo sobre el otro, capturan con menor precisión la paridad entre dos equipos parejos.




Fig. 2. Matrices de confusión normalizadas — conjunto de test.

El análisis por clase permite identificar comportamientos diferentes entre los modelos. El clasificador Bayes M-estimador obtiene sus mejores resultados en las victorias locales y visitantes, con valores de *recall* de 0.64 y 0.58, respectivamente. En cambio, solo identifica el 18 % de los empates y predice 55 empates frente a los 131 observados en test. Por tanto, funciona mejor cuando el resultado favorece a uno de los equipos y tiende a clasificar los encuentros empatados como alguna de las dos posibles victorias.

El ID3 presenta un comportamiento parcialmente opuesto: alcanza el mayor *recall* de empate, con un valor de 0.34, pero obtiene métricas generales inferiores y solo identifica

el 34 % de las victorias visitantes. Random Forest alcanza el mayor recall para las victorias locales, con un valor de 0,67, aunque reconoce apenas el 12 % de los empates. Estos resultados muestran un compromiso entre la capacidad de detectar empates y el rendimiento general sobre las tres clases.

La Figura 3 presenta el mayor F1 macro medio anual observado para cada valor de los hiperparámetros evaluados. Cada punto corresponde al mejor candidato encontrado que utiliza ese valor, mientras que la estrella identifica el valor incluido en la configuración global seleccionada. Los demás hiperparámetros también varían entre candidatos, por lo que la figura compara las mejores configuraciones observadas, pero no mide el efecto aislado de cada valor ni permite afirmar que el seleccionado constituya un óptimo único.

Para el clasificador Bayes, $m = 2$ obtuvo el mayor F1 macro observado, con un valor aproximado de 0,4205. Los valores $m = 0$ y $m = 0,5$ alcanzaron resultados cercanos a 0,4189, por lo que la diferencia es reducida. Esto indica que el rendimiento varía poco entre niveles bajos y moderados de suavizado dentro de las configuraciones evaluadas. En cambio, con $m = 5$ se obtuvo un resultado inferior, cercano a 0,4166.

En el ID3, la configuración seleccionada utiliza $\text{min_info_gain} = 0,00575$ y alcanza un F1 macro aproximado de 0,3961. Otros valores, como 0,0045, 0,007 y 0,0075, obtuvieron resultados muy próximos. No se observa una relación monótona entre el aumento de min_info_gain y el rendimiento. Por tanto, 0,00575 debe interpretarse como el valor incluido en la mejor configuración encontrada durante la búsqueda, y no como un óptimo aislado claramente superior a todas las alternativas.




Fig. 3. Matrices de confusión normalizadas — conjunto de test.

Intervalo de confianza para la tasa de error: Para cada modelo se calcula el intervalo de confianza al 95% de la tasa de error en test, utilizando la aproximación normal de una proporción:

$$\text{error}_s(h) \pm 1.96 \sqrt{\frac{\text{error}_s(h)(1 - \text{error}_s(h))}{n}}$$

donde $\text{error}_s(h) = 1 - \text{accuracy}$ y n es el número de partidos evaluados. Si los intervalos de dos modelos se solapan, no hay evidencia de que uno sea mejor que el otro.

La Tabla II presenta los resultados obtenidos para cada modelo sobre los $n = 472$ partidos del conjunto de test.

Se observa que los intervalos de confianza de Bayes M-estimador, Random Forest, Naive Bayes categórico y el clasificador base se solapan ampliamente entre sí, lo que indica que

TABLE II
INTERVALO DE CONFIANZA AL 95% PARA LA TASA DE ERROR EN TEST.

Modelo	Accuracy	$\text{error}_s(h)$	IC 95%
Árbol ID3 (propio)	0.4089	0.5911	[0.5467, 0.6355]
Bayes M-estimador (propio)	0.4936	0.5064	[0.4613, 0.5515]
Random Forest (sklearn)	0.4873	0.5127	[0.4676, 0.5578]
Naive Bayes categórico (sklearn)	0.4703	0.5297	[0.4846, 0.5747]
Clasificador base (referencia)	0.4640	0.5360	[0.4910, 0.5810]

no hay evidencia estadística suficiente para afirmar que uno de ellos sea significativamente mejor que otro en este conjunto de test. El Árbol ID3, en cambio, presenta el intervalo más alto y con menor solapamiento respecto al resto, lo que sugiere que su rendimiento es inferior al de los demás modelos.

IV. CONCLUSIÓN

La predicción de resultados de fútbol a partir de datos históricos presenta una alta complejidad inherente, debido a la naturaleza estocástica del deporte y al dinamismo de los planteles a lo largo del tiempo.

En los experimentos realizados se observa una marcada dificultad de los cinco modelos para predecir empates: el recall de esta clase no supera 0.34 en ningún caso, y el clasificador base directamente nunca la predice (recall 0.00), pese a contar con una ventana de historial más amplia (diez años) que los modelos entrenados. Esto se debe principalmente a la menor frecuencia de este resultado y al solapamiento de los atributos defensivos y ofensivos entre equipos de rendimiento similar. El hecho de que el clasificador base alcance una *accuracy* competitiva (0.464) pese a ignorar por completo la clase Empate confirma que esta métrica no es, por sí sola, confiable para este problema, y justifica la selección de F1 macro como criterio.

El mejor resultado se obtuvo con el modelo Bayes M-estimador de implementación propia (F1 macro 0.449, *accuracy* 0.494 en test), superando tanto a Random Forest (0.441) como a Naive Bayes categórico de scikit-learn (0.422), y ampliamente al Árbol ID3 propio (0.397) y al clasificador base (0.358). Esto indica que la implementación propia del m-estimador no solo es funcionalmente correcta, sino competitiva frente a alternativas de biblioteca sobre el mismo conjunto de atributos.

Como líneas de mejora se identifican: incorporar atributos diseñados específicamente para detectar paridad entre los equipos, dado que los atributos actuales están orientados principalmente a distinguir ventaja local de visitante, lo que podría explicar la dificultad compartida de los cinco modelos para identificar empates; y extender el análisis de sensibilidad a la ventana temporal de entrenamiento más allá de los diecinueve años evaluados, para verificar si el desempeño se degrada al incorporar épocas muy distintas del fútbol uruguayo.

V. DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

Dado que el curso permite la utilización de herramientas de Inteligencia Artificial de categoría nivel 3 (Uso extendido), vemos pertinente declarar cómo fue su uso. Principalmente, nos apoyamos en la generación de código y/o autocompletado con IA de forma fuertemente supervisada y validada por el equipo. También nos ayudó a reconocer si existían inconsistencias en el dataset proporcionado, automatizando así la búsqueda de las mismas. Además, nos apoyamos en IA para la generación del código encargado de la graficación comparativa de los datos. Asimismo, se utilizó la IA como asistente de escritura de este documento.

REFERENCIAS

- [1] RSSSF, “Uruguay 1987.” rssf
- [2] 1891 BD, “Partidos de Campeonato Uruguayo 1994.” 1891
- [3] 1891 BD, “Partidos de Campeonato Uruguayo 1997.” 1891.
- [4] LARED21, “Ante Nacional, Danubio gana un partido cada once,” 14-dic-2004. lr21.com.uy.
- [5] schochastics, “football-data,” GitHub. github.com/schochastics/football-data.
- [6] Facultad de Ingeniería, Universidad de la República, “Aprendizaje Automático,” Instituto de Computación, Montevideo, Uruguay. Metodología
- [7] Instituto de Computación, Facultad de Ingeniería, Universidad de la República, “Árboles de decisión,” material teórico del curso Aprendizaje Automático, Montevideo, Uruguay. [Online]. Available: eva.fing.edu.uy (Árboles de decisión).
- [8] Instituto de Computación, Facultad de Ingeniería, Universidad de la República, “Aprendizaje bayesiano,” material teórico del curso Aprendizaje Automático, Montevideo, Uruguay. [Online]. Available: eva.fing.edu.uy (Aprendizaje bayesiano).